

Desarrollo de un Modelo Local para la Reestructuración de Interfaces Adaptativas Orientado a la Reducción del Costo de Navegación en Sistemas

Bach. Gutierrez Anco Yesenia Alejandra
yesenia.gutierrez@upeu.edu.pe

Bach. Quispe Apaza Jhosef Mateo
jhosef.quispe@upeu.edu.pe

Bach. Turpo Cayo Jose Alonso
jose.turpo.c@upeu.edu.pe

Universidad Peruana Unión
Facultad de Ingeniería y Arquitectura

May 26, 2026



Contenido General

1. Motivación

Complejidad en Sistemas de Información

Impacto en la Productividad

2. Introducción y Problema

Identificación del Problema

Planteamiento del Problema

Objetivos / Objetivo General /

Objetivos Específicos

3. Marco Teórico

Costo de Navegación

Artículos del Corpus

Modelos de Referencia (SAS, DQN, GRU/Transformers)

4. Proceso Metodológico

Recolección y Preprocesamiento

Modelo de Predicción

Agente DQN

Implementación Local

Evaluación

5. Conclusión

Resumen de Avances

Aportes y Trabajo Futuro

Contenido

1. Motivación

Complejidad en Sistemas de
Información

Impacto en la Productividad

2. Introducción y Problema

Identificación del Problema

Planteamiento del Problema

Objetivos / Objetivo General /

Objetivos Específicos

3. Marco Teórico

Costo de Navegación

Artículos del Corpus

Modelos de Referencia (SAS, DQN,
GRU/Transformers)

4. Proceso Metodológico

Recolección y Preprocesamiento

Modelo de Predicción

Agente DQN

Implementación Local

Evaluación

5. Conclusión

Resumen de Avances


Aportes y Trabajo Futuro

Motivación

Complejidad en Sistemas de Información

Los sistemas de información modernos constituyen entornos de software altamente complejos y multifuncionales. Su arquitectura de módulos genera interfaces con una elevada densidad funcional que impone un alto costo de navegación sobre el usuario.

- Sobrecarga de información visual. [?]
- Menús extensos y estáticos que no se adaptan al usuario. [?]
- Alto costo de búsqueda para tareas frecuentes. [?]



Motivación

Impacto en la Productividad

Los menús estáticos obligan a los usuarios a realizar múltiples clics innecesarios, incrementando el tiempo de ejecución de tareas y la tasa de errores operativos, afectando la eficiencia general del flujo de trabajo [?].




Figura: Esquema del problema de navegación en sistemas ERP. Fuente: Elaboración propia basada en Mughal et al. [?]

Contenido

1. Motivación

Complejidad en Sistemas de
Información

Impacto en la Productividad

2. Introducción y Problema

Identificación del Problema

Planteamiento del Problema

Objetivos / Objetivo General /

Objetivos Específicos

3. Marco Teórico

Costo de Navegación

Artículos del Corpus

Modelos de Referencia (SAS, DQN,
GRU/Transformers)

4. Proceso Metodológico

Recolección y Preprocesamiento

Modelo de Predicción

Agente DQN

Implementación Local

Evaluación

5. Conclusión

Resumen de Avances

Aportes y Trabajo Futuro

Introducción

Sistemas de Información y Costo de Navegación

Los sistemas de información modernos constituyen entornos de software altamente complejos. Su arquitectura de módulos genera interfaces con una elevada densidad funcional que impone un alto costo de navegación sobre el usuario.

Problema central: El costo de navegación, entendido como el esfuerzo cognitivo, temporal y operacional para localizar y ejecutar una función, se agrava drásticamente frente a interrupciones y sobrecarga cognitiva.

Impacto de las Interfaces Estáticas:

- Generan decisiones potencialmente inapropiadas (PID) en contextos de sobrecarga cognitiva. [?]
- Obligan al usuario a navegar estructuras diseñadas para la totalidad del sistema, sin considerar su rol específico.
- Representan una fuente activa de errores y frustración, conforme documentan Balasm et al. en el análisis de sobrecarga visual. [?]

Planteamiento del Problema

La Brecha en la Literatura

A pesar de los avances en interfaces adaptativas, la mayoría de los sistemas de información permanecen relativamente estáticos en su organización de menús y flujos de navegación. [?]

Frente a esto, los Sistemas Auto-Adaptativos (SAS) representan una respuesta arquitectónica consolidada capaz de modificar su comportamiento de forma autónoma. [?]

La Brecha en la Literatura

No existe aún un modelo unificado que integre los principios formales de los SAS con el aprendizaje profundo (Deep Learning + RL) para reestructurar dinámicamente interfaces orientadas a reducir el costo de navegación en sistemas de alta densidad funcional como los ERP.

Objetivo General

Desarrollar un modelo para la reestructuración dinámica de interfaces adaptativas en sistemas de información, orientado a la reducción del costo de navegación del usuario, mediante arquitecturas de aprendizaje profundo para el modelado de interacciones y agentes de aprendizaje por refuerzo bajo los principios de Sistemas Auto-Adaptativos.

Hipótesis principal:

La aplicación del modelo de reestructuración adaptativa basado en Deep Learning (GRU/Transformers) y Aprendizaje por Refuerzo (DQN) reduce en al menos un **30 %** el valor de M1 (clics de

Variables

- **VI:** Activación del modelo DQN
- **VD:** M1 (clics), M2 (tiempo), M3 (error)

Objetivos Específicos

- OE1** Caracterizar el costo de navegación en sistemas mediante la identificación y medición de métricas M1, M2 y M3 derivadas de los registros de interacción del usuario. [? ?]




Objetivos Específicos

- OE1** Caracterizar el costo de navegación en sistemas mediante la identificación y medición de métricas M1, M2 y M3 derivadas de los registros de interacción del usuario. [? ?]
- OE2** Diseñar un modelo de representación del comportamiento de usuario que capture los patrones de navegación secuenciales y prediga intenciones futuras, evaluando arquitecturas LSTM/GRU y Transformers. [? ?]




Objetivos Específicos

- OE1** Caracterizar el costo de navegación en sistemas mediante la identificación y medición de métricas M1, M2 y M3 derivadas de los registros de interacción del usuario. [? ?]
- OE2** Diseñar un modelo de representación del comportamiento de usuario que capture los patrones de navegación secuenciales y prediga intenciones futuras, evaluando arquitecturas LSTM/GRU y Transformers. [? ?]
- OE3** Proponer un algoritmo de reestructuración dinámica de menús basado en Aprendizaje por Refuerzo Profundo (Agente DQN) orientado a minimizar el costo de navegación M1. [? ?]



Objetivos Específicos

- OE1** Caracterizar el costo de navegación en sistemas mediante la identificación y medición de métricas M1, M2 y M3 derivadas de los registros de interacción del usuario. [? ?]
- OE2** Diseñar un modelo de representación del comportamiento de usuario que capture los patrones de navegación secuenciales y prediga intenciones futuras, evaluando arquitecturas LSTM/GRU y Transformers. [? ?]
- OE3** Proponer un algoritmo de reestructuración dinámica de menús basado en Aprendizaje por Refuerzo Profundo (Agente DQN) orientado a minimizar el costo de navegación M1. [? ?]
- OE4** Implementar el modelo de forma local, sin dependencia de servicios externos, garantizando la privacidad de los datos operacionales de la organización. [?]



Objetivos Específicos

- OE1** Caracterizar el costo de navegación en sistemas mediante la identificación y medición de métricas M1, M2 y M3 derivadas de los registros de interacción del usuario. [? ?]
- OE2** Diseñar un modelo de representación del comportamiento de usuario que capture los patrones de navegación secuenciales y prediga intenciones futuras, evaluando arquitecturas LSTM/GRU y Transformers. [? ?]
- OE3** Proponer un algoritmo de reestructuración dinámica de menús basado en Aprendizaje por Refuerzo Profundo (Agente DQN) orientado a minimizar el costo de navegación M1. [? ?]
- OE4** Implementar el modelo de forma local, sin dependencia de servicios externos, garantizando la privacidad de los datos operacionales de la organización. [?]
- OE5** Evaluar la efectividad del modelo DQN mediante un protocolo experimental pre-post que mida la reducción del costo de navegación considerando M1, M2, M3 y satisfacción del usuario. [? ?]

Contenido

1. Motivación

Complejidad en Sistemas de
Información

Impacto en la Productividad

2. Introducción y Problema

Identificación del Problema

Planteamiento del Problema

Objetivos / Objetivo General /

Objetivos Específicos

3. Marco Teórico

Costo de Navegación

Artículos del Corpus

Modelos de Referencia (SAS, DQN,
GRU/Transformers)

4. Proceso Metodológico

Recolección y Preprocesamiento

Modelo de Predicción

Agente DQN

Implementación Local

Evaluación

5. Conclusión

Resumen de Avances

Aportes y Trabajo Futuro

Marco Teórico

Costo de Navegación

El **costo de navegación** es el esfuerzo cognitivo, temporal y operacional que un usuario debe invertir para localizar y ejecutar una función dentro del sistema. [?]

Métricas formales (PPI §2.3.3)

- **M1 — Clics:** Número de interacciones requeridas para alcanzar el módulo objetivo desde la raíz del menú.

$$M1(u, s) = \frac{1}{|s|} \sum_{e \in s} d_{M^*}(e.route)$$

donde $d_{M^*}(f)$ es la profundidad del ítem f en el árbol de menú optimizado por el DQN.

- **M2 — Tiempo:** Duración total desde que el usuario inicia la sesión hasta que alcanza la función deseada.
- **M3 — Error:** Proporción de sesiones con acceso a módulos

Marco Teórico

Modelos de Referencia del Corpus

Carrera-Rivera et al. [?]

Cadenas de Markov para predicción de pasos de navegación en HMI industrial. Base para comparación con GRU.

Todi et al. [?]

RL basado en modelos para adaptación de menús desktop. Base para el agente DQN. [~35 % reducción M1]

Mughal et al. [?]

AIS consciente de interrupciones supera en usabilidad a sistemas no

Päßler et al. [?]

Modelado formal de SAS con feature models y verificación probabilística (ProFeat). Base arquitectónica del subsistema gestor.

Sun et al. [?]

RL data-driven para generación y optimización de UI adaptativas. Referencia de benchmark $\Delta M1 \approx 35\%$.

Gaspar-Figueiredo et al. [?]


Medición de UX con EEG en interfaces adaptativas. Protocolo experi-

Marco Teórico

Sistemas Auto-Adaptativos (SAS)

Un Sistema Auto-Adaptativo (SAS) puede modificar su comportamiento en respuesta a cambios percibidos en su entorno y en sí mismo, tomando decisiones de adaptación de forma autónoma. [?]

Arquitectura de dos capas:



Innovación: Transformar el bucle MAPE-K clásico en un motor

Marco Teórico

Deep Learning y Agente DQN

Componente A — Modelo de Predicción Secuencial (Deep Learning)

Arquitecturas evaluadas:

- **GRU / LSTM** — Redes Neuronales Recurrentes
- **Transformers** — Atención multi-cabeza

Función de predicción: $P(f_{t+1}|f_1, f_2, \dots, f_t) = \text{Softmax}(\text{RNN}(x_1, x_2, \dots, x_t; \theta))$

- **Ventaja sobre Cadenas de Markov:** Retienen dependencias a largo plazo en sesiones del usuario. [? ?]

Componente B — Agente DQN (Deep Q-Network)

Formulación como MDP:

- **Estado** (s_t): Árbol de menú actual + perfil predictivo del usuario
- **Acción** (a_t): Promover ítem / Mover a grupo principal (según RBAC)
- **Recompensa:** $r_t = \Delta M1 = M1_{\text{previo}} - M1_{\text{nuevo}}$

El agente aprende la política óptima π^* que maximiza la eficiencia de la

Marco Teórico

Diferenciación respecto al Corpus

Característica	Carrera-Rivera	Todi et al.	Song et al.	PROPUESTA
Dominio	HMI industrial	Menús desktop	MR	ERP
Modelo predicción	Markov	Heurística	Inferencia Latente	GRU / Transf.
Política adaptación	Recomendación	RL (Q-Learn)	Pareto	DQN Profundo
Ejecución local	No	No	No	Sí (100 %)
Considera RBAC	No	No	No	Sí
Métrica M1 explícita	Indirecta	Indirecta	Sí	Explícita
Reestructura menú	No	Sí	No	Sí

Aporte diferencial central

Primer modelo que integra SAS + Deep Learning (GRU/Transformers) + Deep RL (DQN) para reestructurar interfaces ERP con restricciones RBAC, ejecutándose 100 % de forma local.

Contenido

1. Motivación

Complejidad en Sistemas de
Información

Impacto en la Productividad

2. Introducción y Problema

Identificación del Problema

Planteamiento del Problema

Objetivos / Objetivo General /

Objetivos Específicos

3. Marco Teórico

Costo de Navegación

Artículos del Corpus

Modelos de Referencia (SAS, DQN,
GRU/Transformers)

4. Proceso Metodológico

Recolección y Preprocesamiento

Modelo de Predicción

Agente DQN

Implementación Local

Evaluación

5. Conclusión

Resumen de Avances

Aportes y Trabajo Futuro

OE1 — Recolección y Preprocesamiento

Pipeline de Datos para Deep Learning

La recolección de datos se realiza pasivamente a partir de los logs de interacción, modelando cada evento como una secuencia $\langle \text{usuario}, \text{función}, \text{tiempo} \rangle$ [?].

Pipeline de Preprocesamiento en 3 Etapas

- **Etap 1 — Ventanas Temporales:** Segmentación de eventos en ventanas de observación diaria (24 horas) para capturar la jornada laboral.
- **Etap 2 — Filtración de ruido:** Eliminación de accesos accidentales (< 3 segundos) y sesiones incompletas con menos de dos eventos válidos.
- **Etap 3 — Vectorización Secuencial (Embeddings):** Transformación de rutas en tokens numéricos para construir secuencias de entrada $X = (x_{t-w}, \dots, x_t)$, paso fundamental para la Red Neuronal Recurrente.

OE2 — Modelo de Comportamiento

Predicción Secuencial con Deep Learning

Se implementa una arquitectura neuronal para modelar rutinas complejas:

Componente A — Redes Neuronales Recurrentes o Transformers

- **Arquitecturas:** GRU / LSTM y atención multi-cabeza (Transformers).
- **Objetivo:** Estimar la probabilidad condicional del siguiente paso en el menú:

$$P(f_{t+1} \mid f_1, f_2, \dots, f_t) = \text{Softmax}(\text{RNN}(x_1, x_2, \dots, x_t; \theta))$$

- **Ventaja Crítica:** Resuelve el problema de pérdida de contexto a largo plazo presente en las Cadenas de Markov, capturando secuencias complejas.

OE3 — Reestructuración de Menús

Aprendizaje por Refuerzo Profundo (DQN)

La reestructuración del menú se formula como un Proceso de Decisión de Markov (MDP) [? ?].

Componente B — Agente DQN

- **Estado** (s_t): Árbol de menú actual + perfil predictivo del usuario.
- **Acción** (a_t): Operaciones que reestructuran el árbol (ej. *Promover ítem*, *Mover a grupo principal*).
- **Recompensa** (r_t): Reducción del costo esperado ($r_t = \Delta M1 = M1_{\text{previo}} - M1_{\text{nuevo}}$).

Algoritmo de Ejecución (Restricción RBAC)

La red neuronal evalúa $Q(s, a)$ para cada reestructuración posible. El Agente DQN selecciona la acción óptima de forma iterativa, **respetando estrictamente los permisos** (RBAC) del usuario, hasta alcanzar la política π^* .

OE4 — Implementación Local

Sistemas Auto-Adaptativos (SAS) Offline

Componente C — Ejecución Local

Garantiza que la inferencia neuronal (forward pass de GRU y DQN) ocurra en el servidor ERP usando frameworks optimizados (ej. PyTorch/ONNX) [?].

Restricciones de Privacidad

- Sin llamadas a APIs externas.
- Procesamiento 100 % in-house.
- Cumplimiento ético de privacidad operacional.

OE5 — Evaluación Experimental

Protocolo Pre/Post y Análisis Comparativo

Métricas Clave

- **M1:** Clics desde la raíz.
- **M2:** Tiempo hasta objetivo.
- **M3:** Tasa de error.

Protocolo

- Medición PRE (interfaces estáticas).
- Activación del Agente DQN.
- Medición POST (interfaces dinámicas).

Cuadro: Benchmarks del corpus vs. Propuesta

Trabajo	Dominio	M1
Sun et al. (2024)	Interfaces de software (RL)	~35 %
Carrera-Rivera et al. (2024)	HMI industrial (Markov)	~50 % (MRR)
Propuesta (DQN)	Sistemas ERP	$\geq 30 \%$

Contenido

1. Motivación

Complejidad en Sistemas de Información

Impacto en la Productividad

2. Introducción y Problema

Identificación del Problema

Planteamiento del Problema

Objetivos / Objetivo General /

Objetivos Específicos

3. Marco Teórico

Costo de Navegación

Artículos del Corpus

Modelos de Referencia (SAS, DQN, GRU/Transformers)

4. Proceso Metodológico

Recolección y Preprocesamiento

Modelo de Predicción

Agente DQN

Implementación Local

Evaluación

5. Conclusión

Resumen de Avances

Aportes y Trabajo Futuro



Conclusiones

Estado de los Objetivos Específicos

Logros por OE

OE	Objetivo	Estado	Resultado clave
OE1	Caracterización	Completado	M1=2.148 → M2=695s → M3=10.5 %
OE2	Modelo conducta	Completado	Red Neuronal GRU → Tensores de Secuencia
OE3	Reestructuración	Completado	Agente DQN implementado → Proyección $\geq 30\%$
OE4	Implementación	Completado	$< 2s$ → local → sin internet
OE5	Evaluación	En curso	Pendiente datos reales (≥ 20 usr.)

Conclusiones

Aportes Diferenciales y Trabajo Futuro

Aportes diferenciales

- Primer modelo ERP adaptativo que integra **RBAC** en la reestructuración del menú
- Ejecución **100 % local** (privacidad por diseño, Sans-Ségarra et al. 2021)
- Aplicado a un ERP real con usuarios peruanos (no laboratorio)
- Código reproducible: 5 pipelines Jupyter documentados

Trabajo futuro

- Reclutar ≥ 20 usuarios reales para la fase POST del OE5
- Activar anonimización SHA-256 en producción
- Evaluar con distintos ERP del mercado peruano
- Publicar en LACLO 2026 / CISTI 2026

Referencias I



¡Gracias!

Gutierrez · Quispe · Turpo

Escuela de Ingeniería de Sistemas · UPeU · 2026

