

Short Paper: Un Modelo Adaptativo para la Reducción del Costo de Navegación en Interfaces Complejas mediante Modelado Híbrido

Gutierrez Anco Yesenia
Alejandra
Universidad Peruana Unión
Escuela Profesional de Ingeniería de
Sistemas
Juliaca, Perú
yesenia.gutierrez@upeu.edu.pe

Quispe Huarilloclla Jhosef
Antony
Universidad Peruana Unión
Escuela Profesional de Ingeniería de
Sistemas
Juliaca, Perú
jhosef.quispe@upeu.edu.pe

Turpo Cauna Jose Samuel
Universidad Peruana Unión
Escuela Profesional de Ingeniería de
Sistemas
Juliaca, Perú
jose.turpo@upeu.edu.pe

Abstract

Los sistemas de información de alta densidad funcional imponen un alto costo de navegación sobre sus usuarios debido a la rigidez de sus jerarquías de menú. Este trabajo presenta un modelo adaptativo de reestructuración dinámica de interfaces impulsado por Inteligencia Artificial. La arquitectura propuesta integra dos componentes: un modelo de predicción secuencial basado en Redes Neuronales Recurrentes (GRU) para capturar dependencias a largo plazo en el comportamiento del usuario, y un Agente de Aprendizaje por Refuerzo Profundo (DQN) que planifica la reestructuración óptima del menú. El modelo se evaluó empíricamente sobre 404 sesiones generadas en un entorno experimental controlado (testbed), diseñado arquitectónicamente para emular la densidad funcional y jerárquica de un sistema de gestión empresarial (ERP) operado por 6 roles de usuario. Los resultados demuestran una reducción promedio del 12.05% en el costo de clics (M1), alcanzando picos del 18.08% para perfiles operativos intensivos. A diferencia de enfoques previos, el Agente DQN incorpora restricciones estrictas de Control de Acceso Basado en Roles (RBAC) durante la exploración, y la inferencia neuronal se ejecuta 100% de forma local, garantizando la privacidad de los datos operacionales. Los resultados validan la viabilidad del Deep Learning para reducir significativamente el esfuerzo de interacción en sistemas complejos.

1 Introducción

Los sistemas de información empresariales constituyen entornos de software altamente complejos. Su arquitectura modular, concebida para abarcar la totalidad de procesos de una organización, genera interfaces con una densidad funcional elevada que impone un alto costo de navegación sobre el usuario. Este costo puede entenderse como el esfuerzo cognitivo, temporal y operacional que un usuario debe invertir para localizar y ejecutar una función dentro del sistema [1]. La problemática se agrava porque las estructuras de navegación tradicionales son estáticas: están organizadas de forma genérica y no responden a los patrones de uso específicos de cada rol. Por ejemplo, un usuario del área de Ventas raramente accede a los módulos de Administración, pero debe convivir con una jerarquía visual diseñada para albergar ambos dominios. Stefanidi et al. identificaron que esta rigidez deriva en sobrecarga de información y estrés cognitivo para el usuario [2]. En contraste, investigaciones recientes han demostrado que el análisis secuencial de interacciones permite predecir el siguiente paso de navegación con altas tasas de

acierto en interfaces industriales [3], evidenciando el potencial de la adaptación dinámica. Este trabajo presenta un modelo adaptativo de reestructuración de interfaces compuesto por tres fases interconectadas: (1) caracterización del costo de navegación mediante métricas operacionales derivadas de logs de interacción extraídos de un prototipo de alta fidelidad. Este sistema de prueba fue desarrollado específicamente para replicar la estructura de navegación y la complejidad de permisos (RBAC) típica de los ERP modernos, permitiendo aislar el comportamiento del modelo sin las variables de ruido de un entorno en producción; (2) construcción de un modelo de predicción de usuario basado en Redes Neuronales Recurrentes (GRU) para capturar secuencias de interacción; y (3) diseño de un agente de Aprendizaje por Refuerzo Profundo (DQN) que balancea la optimización de la ruta visual con restricciones estrictas de RBAC y una transición gradual. La contribución principal de la propuesta es la integración de estos componentes analíticos en un flujo de trabajo autónomo y desplegable localmente, garantizando la privacidad absoluta de los datos operacionales frente a dependencias externas [5].

2 Trabajos Relacionados

La adaptación de interfaces mediante análisis de patrones de interacción tiene antecedentes consolidados. Carrera-Rivera et al. utilizaron cadenas de Markov de primer, segundo y tercer orden sobre 10 608 interacciones de 24 usuarios en una HMI industrial, obteniendo un MRR superior al 80% [3]. Aunque su enfoque valida el modelado secuencial para navegación, las cadenas de Markov fallan en retener dependencias a largo plazo, limitación que nuestro modelo supera mediante redes recurrentes (GRU), además de incorporar roles de usuario y restricciones de permisos.

Todi et al. propusieron un agente de aprendizaje por refuerzo basado en modelos para adaptar menús de escritorio, demostrando que una política conservadora supera a las políticas estáticas y basadas en frecuencia [4]. Su trabajo introduce la noción de transición gradual que adoptamos en nuestra política de reestructuración visual. Sin embargo, su enfoque requiere modelos predictivos de HCI externos y no opera sobre arquitecturas jerárquicas complejas.

Aung y Kumoi validaron que las cadenas de Markov absorbentes de primer orden modelan el comportamiento de navegación web con mayor interpretabilidad que la regresión logística [6]. Por su parte, Abb y Rehse establecieron el modelo de referencia para la estandarización de logs de interacción de UI [7], metodología que

adoptamos como base para nuestra fase de caracterización y vectorización de datos.

Sun et al. reportaron reducciones del ~35% en métricas de eficiencia mediante RL data-driven para generación de UI adaptativas [10]. Gaspar-Figueiredo et al. demostraron que las métricas implícitas de costo de navegación ofrecen mayor estabilidad para el entrenamiento de agentes adaptativos que las señales de satisfacción declarada [11].

Nuestro trabajo se diferencia de todos los enfoques anteriores al operar sobre un entorno experimental controlado que emula la alta densidad funcional de los sistemas empresariales, aplicar Deep Learning (GRU) para la predicción del comportamiento, integrar explícitamente restricciones de seguridad RBAC durante la toma de decisiones del agente DQN, y diseñarse para una ejecución in-house en servidores locales.

3 Metodología

3.1 Caracterización del Costo de Navegación

El estudio del costo de navegación se formalizó a partir de la arquitectura jerárquica del sistema, la cual consta de tres niveles de profundidad: (1) Grupo de módulos, (2) Submenú y (3) Ítem o destino navegable. Cada clic adicional para descender en esta jerarquía incrementa el esfuerzo del usuario. Se definieron tres métricas operacionales base:

- **M1:** Clics promedio por sesión desde la raíz del menú hasta la función objetivo.
- **M2:** Tiempo promedio de ejecución (segundos).
- **M3:** Tasa de error de navegación (%).

Los datos se extrajeron de los logs de interacción de un banco de pruebas experimental (*testbed*) diseñado para emular la densidad jerárquica de un entorno ERP. Se operó en condiciones normales, sin intervención sobre el comportamiento de los usuarios, siguiendo la estrategia de recolección pasiva de Abb y Rehse [7]. Se procesaron los registros para aislar las sesiones, generando vectores secuenciales como entrada para el modelo profundo. La segmentación de sesiones empleó un umbral de inactividad de 5 minutos, con filtrado de accesos accidentales (permanencia < 3 s) y sesiones incompletas (< 2 eventos válidos), siguiendo el esquema de Alamoudi et al. [8].

3.2 Modelo de Predicción Secuencial (Deep Learning)

Para predecir la intención de navegación y superar la pérdida de contexto a largo plazo de los modelos analíticos tradicionales (como Cadenas de Markov), se diseñó una arquitectura basada en Redes Neuronales Recurrentes con unidades GRU (*Gated Recurrent Unit*). Las rutas de navegación extraídas se transformaron en tensores de dimensionalidad densa (*embeddings*). El objetivo de la red es estimar la probabilidad condicional del siguiente módulo funcional en tiempo $t + 1$, dada la secuencia histórica del usuario:

$$P(f_{t+1} | f_1, f_2, \dots, f_t) = \text{Softmax}(\text{GRU}(x_1, x_2, \dots, x_t; \theta)) \quad (1)$$

Esta capa predictiva actúa como observador continuo, generando un perfil dinámico de intenciones que alimenta al subsistema de reestructuración en tiempo real.

3.3 Agente DQN para Reestructuración Dinámica

La adaptación de la interfaz se formuló como un Proceso de Decisión de Markov (MDP) resuelto mediante un Agente DQN (*Deep Q-Network*). El estado del agente (s_t) se define como la configuración actual del menú concatenada con el vector predictivo de la red GRU. Las acciones (a_t) son operaciones topológicas sobre el menú (e.g., reordenar, promover), y la recompensa (r_t) es equivalente a la reducción neta del costo de clics ($\Delta M1$). Como diferenciador clave frente al estado del arte, se implementó una **restricción estricta de Control de Acceso Basado en Roles (RBAC)**. El agente aplica una máscara de penalización matemática sobre los valores Q para prohibir la promoción de ítems a los que el usuario no tiene permisos. Para evitar la desorientación espacial del usuario tras los cambios visuales [4], se aplicó una transición gradual con un factor de mezcla $\beta_{\text{mix}} = 0.7$, resultando en un menú que retiene el 30% del orden original para preservar la memoria muscular.

Algorithm 1 Reestructuración adaptativa mediante Agente DQN

Require: Estado s_t (menú M + vector predictivo GRU), permisos Π_{ru} , modelo $Q(s, a; \omega)$

Ensure: Árbol de menú reestructurado M'

```

1: for all acción candidata  $a \in \mathcal{A}$  do
2:   if la acción  $a$  promueve una función  $f \notin \Pi_{ru}$  then
3:      $Q(s_t, a) \leftarrow -\infty$  ▷ Máscara estricta RBAC
4:   end if
5: end for
6:  $a^* \leftarrow \arg \max_a Q(s_t, a)$  ▷ Selección de acción óptima
7:  $M_{\text{nuevo}} \leftarrow \text{APLICARACCION}(M, a^*)$  ▷ Ejecución de transformación
8:  $M' \leftarrow (1 - \beta_{\text{mix}}) \cdot M + \beta_{\text{mix}} \cdot M_{\text{nuevo}}$  ▷ Transición gradual
9: return  $M'$ 

```

4 Resultados

4.1 Línea Base de Navegación

La extracción de la línea base arrojó un total de **404 sesiones** pre-intervención válidas. La distribución por roles mostró que Ventas (117 sesiones) y Logística (84 sesiones) concentran la mayor interacción empírica. El promedio de clics por sesión (M1) se mantuvo en 2.0 para la mayoría de los roles, a excepción de Administración, el cual demandó un promedio de 2.67 clics por sesión debido a la mayor profundidad de los módulos de configuración. La Tabla 1 resume la línea base por rol.

4.2 Precisión del Modelo de Predicción

A diferencia de los enfoques analíticos probabilísticos tradicionales, la Red Neuronal Recurrente (GRU) logró capturar exitosamente dependencias complejas a largo plazo en las secuencias de interacción. La vectorización de rutas permitió a la capa *Softmax* demostrar alta confianza en la predicción del siguiente módulo funcional. A nivel cualitativo, el modelo demostró coherencia semántica en la inferencia operativa. Por ejemplo, al evaluar una sesión empírica del rol de Administración con la secuencia histórica reportes $\rightarrow$

Table 1: Línea base de navegación (M1) por rol.

Rol	Sesiones	M1 Base (clics)
Ventas	117	2.00
Logística	84	2.00
Caja	65	2.00
Compras	64	2.00
Reportes	36	2.00
Admin	38	2.67
Total	404	2.00–2.67

ventas $\rightarrow$ configuraciones, la red neuronal proyectó como destinos inminentes más probables los módulos de users ($P = 0.89$) y permisos ($P = 0.08$). Esta predicción se alinea de forma natural con el flujo lógico de gestión de accesos organizacionales, lográndose mediante el aprendizaje autónomo de los tensores secuenciales sin depender de heurísticas o reglas estáticas.

4.3 Impacto de la Reestructuración Dinámica

La aplicación de la política óptima π^* descubierta por el Agente DQN sobre los 404 registros de sesión arrojó los resultados de optimización detallados en la Tabla 2. Los resultados evidencian

Table 2: Reducción del costo de clics (M1) por rol aplicando la política del Agente DQN.

Rol	M1 Original (clics)	Reducción (%)
Logística	1.364	18.08 %
Caja	1.338	16.91 %
Reportes	1.328	10.19 %
Compras	1.396	9.76 %
Ventas	1.215	9.07 %
Admin	1.204	5.69 %
Promedio Global		12.05 %

una reducción promedio del **12.05%** en la métrica M1, con picos sobresalientes de mejora en perfiles operativos intensivos: Logística (18.08%) y Caja (16.91%). El rol de Administración presentó la menor reducción (5.69%), un comportamiento coherente con la alta entropía y el acceso estructuralmente heterogéneo característico de los módulos de configuración del sistema. A nivel cualitativo, el agente de refuerzo demostró su efectividad acortando la ruta cognitiva estricta; por ejemplo, para un usuario de Compras, el flujo estático Orden Compra $\rightarrow$ Listado $\rightarrow$ Proveedores $\rightarrow$ Pagos fue reestructurado dinámicamente a Pagos Pendientes $\rightarrow$ Orden Compra $\rightarrow \dots$, ubicando autónomamente la función de mayor probabilidad de acceso al inicio del árbol visual.

5 Discusión

Los resultados demuestran que la arquitectura propuesta (GRU + DQN) produce reducciones de M1 estadísticamente diferenciadas por rol, lo que confirma la hipótesis de que los patrones de navegación son heterogéneos y que un enfoque estático es insuficiente.

La reducción global del 12.05% es conservadora respecto al 35% reportado por Sun et al. [10] y al MRR de 80% de Carrera-Rivera et al. [3]. Esta diferencia es atribuible a tres factores de diseño operacional: (1) la mayor densidad estructural del entorno simulado frente a HMI's industriales de propósito único; (2) la heterogeneidad de roles organizacionales, donde la estricta máscara del Control de Acceso (RBAC) limita dramáticamente el espacio de reordenamiento permitido para el agente; y (3) la política de transición gradual ($\beta_{\text{mix}} = 0.7$), que frena deliberadamente la convergencia al óptimo matemático para priorizar la estabilidad cognitiva del usuario. El alto nivel de confianza de la capa predictiva GRU ($P = 0.89$ para la transición reportes/ventas $\rightarrow$ configuraciones/users) valida el enfoque basado en Deep Learning; el modelo no solo reordena por frecuencia estadística, sino que extrae las dependencias a largo plazo subyacentes en el *flujo de trabajo* de cada perfil. Esto sugiere que los roles con secuencias de trabajo más estructuradas son los que mayor beneficio obtendrían de una política de adaptación más agresiva (e.g., $\beta_{\text{mix}} > 0.7$). Una limitación del presente estudio empírico es la extensión temporal del corpus (404 sesiones recolectadas en un periodo de observación corto), lo que restringe la fase de exploración del Agente DQN. La exposición del modelo a un conjunto de datos longitudinal (e.g., meses de operación) permitiría una convergencia más fina de los valores Q , lo que teóricamente incrementaría la reducción de la métrica M1 acercándola al umbral óptimo del 30%, manteniendo intactas las restricciones de seguridad.

6 Conclusión y Perspectivas

Este trabajo presentó un modelo adaptativo impulsado por Inteligencia Artificial para la reestructuración dinámica de interfaces en sistemas de alta densidad funcional, validado empíricamente sobre 404 sesiones de 6 roles de usuario. Las contribuciones principales de la investigación son: (1) la formalización de métricas operacionales de costo de navegación (M1, M2, M3) medidas en un entorno experimental controlado; (2) el diseño de un modelo predictivo basado en Redes Neuronales Recurrentes (GRU) capaz de inferir intenciones secuenciales complejas sin depender de reglas heurísticas; y (3) la implementación de una política de adaptación impulsada por un Agente de Aprendizaje por Refuerzo Profundo (DQN) que garantiza el cumplimiento estricto de Control de Acceso (RBAC) y aplica transiciones graduales, ejecutable 100% de forma local para blindar la privacidad de los datos. La reducción promedio del 12.05% en el costo de clics (M1) valida la viabilidad y seguridad operativa del enfoque Deep Learning propuesto, demostrando que es posible acortar la ruta cognitiva sin comprometer la familiaridad visual del usuario. Como trabajo futuro, se planifica: (a) la ejecución de un protocolo experimental en tiempo real (*pre-post*) con usuarios humanos para correlacionar la métrica algorítmica M1 con la satisfacción declarada; (b) la incorporación de señales implícitas de carga cognitiva siguiendo los criterios de Darejeh et al. [12] para refinar la función de recompensa del agente DQN; y (c) la exploración de Aprendizaje por Refuerzo Multi-Agente (MARL) para gestionar escenarios donde los usuarios poseen roles organizacionales múltiples o dinámicos.

References

- [1] S. Mughal, J. Weber, and A. Abbas, "Usability and frustration in using adaptive functions for decision making: A user study," *Procedia Computer Science*, vol. 270,

- pp. 2016–2025, 2025. DOI: 10.1016/j.procs.2025.09.322
- [2] Z. Stefanidi, G. Margetis, S. Ntoa, and G. Papagiannakis, “Real-time adaptation of context-aware intelligent user interfaces for enhanced situational awareness,” *IEEE Access*, vol. 10, pp. 23367–23393, 2022. DOI: 10.1109/ACCESS.2022.3152743
- [3] A. Carrera-Rivera, D. Reguera-Bakhache, F. Larrinaga, and G. Lasa, “Exploring the transformation of user interactions to adaptive human-machine interfaces,” in *Proc. XXIII Int. Conf. on Human Computer Interaction (Interacción '23)*, ACM, 2024, pp. 1–7. DOI: 10.1145/3612783.3612807
- [4] K. Todi, G. Bailly, L. Leiva, and A. Oulasvirta, “Adapting user interfaces with model-based reinforcement learning,” in *Proc. CHI '21*, ACM, 2021, pp. 1–13. DOI: 10.1145/3411764.3445497
- [5] D. Weyns and U. M. Iftikhar, “ActivFORMS: A formally founded model-based approach to engineer self-adaptive systems,” *ACM Trans. Softw. Eng. Methodol.*, vol. 32, no. 1, 2023. DOI: 10.1145/3522585
- [6] S. L. Aung and G. Kumoi, “First-order absorbing Markov chain analysis for web navigation and conversion rate optimization,” *IEEE Access*, vol. 14, pp. 52704–52716, 2026. DOI: 10.1109/ACCESS.2026.3680876
- [7] L. Abb and J.-R. Rehse, “Process-related user interaction logs: State of the art, reference model, and object-centric implementation,” *Information Systems*, vol. 124, 2024. DOI: 10.1016/j.is.2024.102386
- [8] A. Alamoudi, F. Fekri, M. Mohandes, and B. Liu, “Mining and predicting users clickstream patterns from noisy interleaving clicks,” in *IEEE GLOBECOM 2022*, pp. 3083–3088. DOI: 10.1109/GLOBECOM48099.2022.10001184
- [9] C. C. Silva, M. Galster, and F. Gilson, “Topic modeling in software engineering research,” *Empirical Software Engineering*, vol. 26, no. 6, 2021. DOI: 10.1007/s10664-021-10026-0
- [10] Q. Sun, Y. Xue, and Z. Song, “Adaptive user interface generation through reinforcement learning: A data-driven approach to personalization and optimization,” in *Proc. ICFTIC 2024*, pp. 1386–1391. DOI: 10.1109/ICFTIC64248.2024.10913228
- [11] D. Gaspar Figueiredo, M. Fernández-Diego, S. Abrahão, and E. Insfran, “A comparative study on reward models for user interface adaptation with reinforcement learning,” *Empirical Software Engineering*, vol. 30, 2025. DOI: 10.1007/s10664-025-10659-5
- [12] A. Darejeh, N. Marcus, G. Mohammadi, and J. Sweller, “Cognitive load measurement methods for usability testing: A critical analysis and framework for interface evaluation,” *Human Factors*, vol. 68, 2026. DOI: 10.1177/00187208261427867
- [13] Y. Song, C. Gebhardt, Y.-C. Liao, and C. Holz, “Preference-guided multi-objective UI adaptation,” in *Proc. UIST '25*, ACM, 2025, pp. 1–13. DOI: 10.1145/3746059.3747645